

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ	Информатика и системы управления и искусственный интеллект
КАФЕДРА	Системы обработки информации и управления

Рубежный контроль №2

По курсу

«Методы машинного обучения»

«Методы обработки текстов»

Студент	Костарев А. П.		
•	подпись, дата	фамилия, и .о.	
Преподаватель		Гапанюк Ю. Е.	
•	подпись, дата	фамилия, и .о	

Задание

Необходимо решить задачу классификации текстов на основе любого выбранного Вами датасета (кроме примера, который рассматривался в лекции). Классификация может быть бинарной или многоклассовой. Целевой признак из выбранного Вами датасета может иметь любой физический смысл, примером является задача анализа тональности текста.

Необходимо сформировать два варианта векторизации признаков - на основе CountVectorizer и на основе TfidfVectorizer.

Классификатор 1 (согласно варианту): LinearSVC

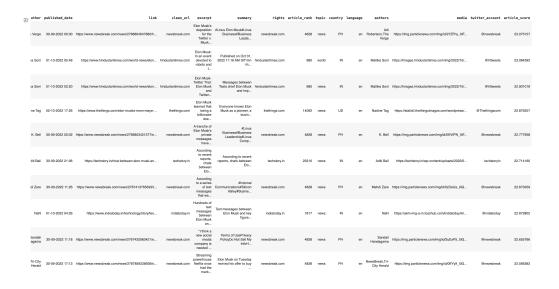
Классификатор 2 (согласно варианту): LogisticRegression

Выполнение задания

```
[1] from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer from sklearn.model_selection import train_test_split from sklearn.svm import LinearSVC from sklearn.linear_model import LogisticRegression from sklearn.metrics import accuracy_score import pandas as pd import time
```

```
У [2] # Загрузка данных df = pd.read_csv('Elon_musk_articles.csv')
```

[3] df.head(10)



(4) df.info()

<<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5000 entries, 0 to 4999
Data columns (total 17 columns):

#	Column	Non-N	Null Count	Dtype		
0		5000	non-null	object		
	_id			object		
1	title	5000	non-null	object		
2	author	4438	non-null	object		
3	<pre>published_date</pre>	5000	non-null	object		
4	link	5000	non-null	object		
5	clean_url	5000	non-null	object		
6	excerpt	4962	non-null	object		
7	summary	4986	non-null	object		
8	rights	4966	non-null	object		
9	article_rank	5000	non-null	int64		
10	topic	5000	non-null	object		
11	country	5000	non-null	object		
12	language	5000	non-null	object		
13	authors	4438	non-null	object		
14	media	4962	non-null	object		
15	twitter_account	3538	non-null	object		
16	article_score	5000	non-null	float64		
<pre>dtypes: float64(1), int64(1), object(15)</pre>						
memory usage: 664.2+ KB						

```
У [5] # проверим пропуски в данных и устраним их na_mask = df.isna() na_counts = na_mask.sum() na_counts
```

```
\overline{\Rightarrow}
    _id
                              0
                              0
     title
     author
                            562
     published_date
                              0
     link
                              0
                              0
     clean_url
     excerpt
                             38
     summary
                             14
     rights
                             34
     article_rank
                              0
                              0
     topic
                              0
     country
     language
                              0
     authors
                            562
    media
                             38
     twitter_account
                           1462
     article_score
                              0
     dtype: int64
```

```
[6] df.dropna(inplace=True)
    na_mask = df.isna()
    na_counts = na_mask.sum()
    na_counts
<u>→</u> _id
    title
                        0
    author
                        0
    published_date
                        0
                        0
    link
    clean_url
                        0
    excerpt
                        0
                        0
    summary
                        0
    rights
    article_rank
                        0
    topic
                        0
    country
                        0
    language
                        0
    authors
    media
                        0
    twitter_account
                        0
    article_score
    dtype: int64
```

```
[7] # Разделим набор данных на обучающую и тестувую выборки
    X, Y = df['summary'], df['topic']
    X_train, X_test, y_train, y_test = train_test_split(X, Y, test_size=0.2, random_state=42)
    time_arr = []

[8] # векторизация признаков с помощью CountVectorizer
    count_vect = CountVectorizer()
    X_train_counts = count_vect.fit_transform(X_train)
    X_test_counts = count_vect.transform(X_test)

[9] # векторизация признаков с помощью TfidfVectorizer
    tfidf_vect = TfidfVectorizer()
    X_train_tfidf = tfidf_vect.fit_transform(X_train)
    X_test_tfidf = tfidf_vect.transform(X_test)
```

```
| # LinearSVC | gbc = LinearSVC() | start_time = time.time() | start_time | time = time.time() | start_time | time.arr.append(train_time) | pred_gbc_counts = gbc.predict(X_test_counts) | print("Toчность (CountVectorizer + LinearSVC):", accuracy_score(y_test, pred_gbc_counts)) | # Logistic Regression | lr = Logistic Regression(max_iter=2000) | start_time = time.time() | lr.fit(X_train_counts, y_train) | train_time = time.time() - start_time | time_arr.append(train_time) | pred_lr_counts = lr.predict(X_test_counts) | print("Toчность (CountVectorizer + LogisticRegression):", accuracy_score(y_test, pred_lr_counts)) |
```

// usr/local/lib/python3.10/dist-packages/sklearn/swm/_base.py:1244: ConvergenceWarning: Liblinear failed to converge, increase the number of iterations. warnings.warn(
Точность (CountVectorizer + LinearSVC): 0.7315541601255887
Точность (CountVectorizer + LogisticRegression): 0.7770800627943485

```
🏏 [13] # Произведем обучения вдух классификаторов (по варианту) для TfidfVectorizer
        # LinearSVC
        gbc = LinearSVC()
        start_time = time.time()
        gbc.fit(X_train_tfidf, y_train)
train_time = time.time() - start_time
        time_arr.append(train_time)
        pred\_gbc\_tfidf = gbc.predict(X\_test\_tfidf)
        print("Точность (TfidfVectorizer + LinearSVC):", accuracy_score(y_test, pred_gbc_tfidf))
        # Logistic Regression
        lr = LogisticRegression(max_iter=2000)
        start_time = time.time()
        lr.fit(X_train_tfidf, y_train)
        train_time = time.time() - start_time
        time_arr.append(train_time)
        pred_lr_tfidf = lr.predict(X_test_tfidf)
        print("Точность (TfidfVectorizer + LogisticRegression):", accuracy_score(y_test, pred_lr_tfidf))
   Точность (TfidfVectorizer + LinearSVC): 0.8037676609105181
Точность (TfidfVectorizer + LogisticRegression): 0.8084772370486556
```

₹	Связка	 Точность валидации	 Время обучения
	(TfidfVectorizer + LogisticRegression)	-=====================================	1.77126
	(TfidfVectorizer + LinearSVC)	0.803768	84.5727
	(CountVectorizer + LogisticRegression)	0.77708	4.12995
	(CountVectorizer + LinearSVC)	0.731554	52.7793